

Sequençage d'ARN : Analyse de données et identification des sous-types cellulaires

Kenza Kadri^a

^aSorbonne Université - Master 2 Biologie des Systèmes

Lors du développement d'un organisme, on observe des déformations tissulaires expliquées notamment par des divisions cellulaires, de l'apoptose ou encore de la différenciation. Nous nous intéressons ici à la morphogénèse du notum (tissu épithélial dorsale) chez la drosophile. Ces déformations sont dû à des expressions locales de gènes différents. Le séquençage d'ARN (ou RNA-seq en anglais) et une technique de séquençage à haut débit permettant l'identification et la quantification de ces expressions indirectement via la quantification d'ARNm. Ce type de séquençage nécessite des techniques d'analyse de grandes bases de données. Nous avons discriminé 15 groupes différents de cellules à l'aide du paquet PAGA. Ces groupes peuvent être fusionnés en 6 groupes de cellules, les cellules épithéliales, les cellules musculaires, et des groupes mixes.

Séquençage d'ARN | Identification cellulaire | Python | Inférence du sous-type cellulaire

Introduction

La drosophile (*Drosophila Melanogaster*) est un modèle très prisé en recherche scientifique depuis plus d'un siècle (1). En effet, sa petite taille, son faible coût ou encore son petit nombre de chromosomes (2) en font un modèle privilégié pour des études de génétiques, médecine ou encore de physiologie. Le génome de la drosophile a d'ailleurs été entièrement séquencé en 2008 (3). De plus, l'édition de son génome par CRISPR-Cas9 semble assez aisé, ce qui permet d'étudier l'impact de certaines mutations sur son phénotype (4). La drosophile a en effet été utilisée pour étudier de nombreux processus retrouvés chez les mammifères. Avec plus de 13 000 gènes homologues au génome humain (3), et 4 chromosomes (2), ce modèle a permis la découverte de nombreuses voies de signalisation tel qu'une voie impliquée dans le rythme circadien (5)(6) ayant conduit au prix Nobel de physiologie en 2017 (7). Un autre prix Nobel a été attribué à Thomas Morgan pour ses travaux sur l'hérédité, toujours sur la drosophile (1). Les travaux sur le récepteur Toll (voie Toll impliquée dans l'immunité innée) ont été réalisés sur ce modèle et ont conduit Jules Hoffman au Prix Nobel de physiologie en 2011 (8). La drosophile a aussi été utilisée pour l'étude du développement avec notamment la découverte de la voie de signalisation Notch (impliquée dans la neurogenèse) (9) ou encore le rôle de certains gènes dans l'embryogenèse ayant conduit à un autre prix Nobel de physiologie en 1995 (10). Ainsi, la drosophile semble être un modèle de choix, notamment concernant les facteurs génétiques impliqués dans la morphogénèse. En effet, la morphogénèse regroupe les processus développementaux cellulaires et tissulaires au cours de l'embryogenèse (11). Ce processus correspond à une succession de division et de mort cellulaire (12). Or, ce phénomène est observable chez la drosophile au niveau du notum, la partie dorsale de cette dernière (13). Lors de la morphogénèse on observe une déformation de certains tissus, notamment des tissus épithéliaux (14). En effet, les tissus épithéliaux, tissus de

contact entre l'organisme et l'environnement, sont en constant renouvellement (15). Ces tissus sont essentiels à la structure d'un organisme, par le rôle de support mécanique, de barrière contre les pathogènes ou encore de frontière de délimitation entre deux milieux physico-chimiques différents (16). L'essentiel des tissus épithéliaux sont regroupés en mono-couche cellulaires, les cellules les constituant pouvant se déformer pour se transformer en cellules migratrices et permettre le remodelage des tissus (17). Ces déformations sont dû à des expressions locales de gènes différents (18).

Ceci étant aussi possible de par les jonctions dynamiques que l'on retrouve au niveau de ces cellules (16). On retrouve notamment des jonctions adhérentes constituées d'E-cadhérine indispensable à cette dynamique (19).

Or, on sait depuis quelques années que des mutations peuvent affecter la morphogénèse à différents stades de développement, tel que la mutation d'un gène codant la spectrine apicale par exemple (20). Toujours d'après la littérature, des anomalies de la polarité et de la prolifération cellulaires dans les tissus épithéliaux seraient corrélées à la formation de néoplasie (ou tumeur) (21).

Aussi l'étude de la déformation des tissus épithéliaux semble être nécessaire dans la compréhension des mécanismes sous-jacents de la morphogénèse. Le séquençage de l'ARNm peut permettre d'étudier ce phénomène d'un point de vue génétique. L'identification des gènes impliqués dans la morphogénèse pourrait conduire in fine à des modèles de morphogénèse de plus en plus complexes (22).

Sachant que nous étudions des expressions locales de gènes, le séquençage d'ARNm sur cellule unique permet l'identification et la quantification d'ARNm d'une cellule (23) est une bonne alternative. Cette technique permet de mettre en évidence et de quantifier les ARNm présents dans une cellule à un moment donné (23). Or, on sait que l'étude du transcriptome (c'est à dire des ARNs transcrits par une cellule à un moment donné) donne une indication relative sur l'expression des gènes au moment du séquençage (23).

Or, cette technique engendre de grandes bases de données à analyser, c'est d'ailleurs un des grands enjeux du XXI^{ème} siècle (24). Ici, nous nous intéressons donc à l'étude des déformations du tissu épithélial des cellules dorsales de la drosophile d'un point de vue génétique, à différents moments du développement. Plus précisément, on s'intéresse ici au phénomène de prolifération cellulaire sous-jacent à la déformation épithéliale. Pour se faire, nous tenterons de mettre en place un protocole d'analyse de données qui aura pour but l'identification de sous-types cellulaires. En effet, nous nous intéressons aux cellules épithéliales, or, lors de la dissection d'autres types cellulaires ont été prélevées. Pour se faire nous possédons donc

Personne à contacter : E-mail : kenza.kadri-1@etu.sorbonne-universite.fr

les résultats du séquençage comprenant le noms des cellules à trier, et les gènes qui sont exprimés pour ces cellules. Dans un premier temps nous filtrerons nos données pour réduire les biais associés au séquençage. Ensuite nous émettrons plusieurs hypothèse de catégorisation de ces cellules pour tenter de discriminer les groupes cellulaires. L'objectif de ce rapport est de choisir une méthode de classification et ainsi d'obtenir la liste des cellules épithéliales, qui permettrons de continuer le travail de modélisation en aval de ce travail.

Matériels et méthodes

Séquençage des ARNm sur cellules uniques.

Prélèvement des tissus. Les tissus ont été prélevés sur la partie dorsale d'une drosophile (le *notum*). L'objectif étant de récupérer des cellules épithéliales, cependant il est difficile des isoler des autres types cellulaires adjacents. Le tissu prélevé contient donc des cellules épithéliales, et des contaminations d'autres types. Les autres types de tissu correspondent à des cellules musculaires, des cellules de tendons, des cellules précurseuses de muscles, des cellules sanguines et enfin des cellules précurseurs des organes sensoriels (SOP). Aussi un filtrage sera réaliser en aval du séquençage.

Isolation des cellules. Le séquençage de l'ARNm a été réalisé à partir des tissus prélevés dans la partie dorsale d'une drosophile. Tout d'abord on isole les cellules, pour se faire on utilise la microfluidique. Cette "technique" consiste à faire passer des cellules une à une dans un gel le long de microcanaux. Dans ces microcanaux on aura aussi des GEM (ou Gel bead in EMulsion), des billes possédant un code barre unique (ou barcode en anglais) d'une longueur de 10 à 15 bases aléatoires). Une cellule va s'accrocher à une bille et sera emprisonnée dans une goutte d'huile. Ainsi on aura une cellule pour une bille avec un identifiant unique. A ce GEM on aura plusieurs identification unique moléculaire ou UMIs (pour Unique molecular Identifiers en anglais) permettant de marquer (ou tagué en anglais) chaque ARNm sur la bille. On aura aussi une séquence polyT pour permettre la fixation du dit ARNm à la bille (fig.1).

Rétrotranscription de l'ARNm en ADNc. Les réactifs présents dans la gouttelettes permettent la lyse de la cellule. Ainsi, la queue polyA de l'ARNm pourra s'hybrider avec la queue polyT qui elle-même est accrochée à la bille par le biais de l'UMI. D'autres réactifs permettent la rétrotranscriptions de l'ARNm en ADNc (retropolymérase). Ainsi, chaque ADNc d'une même gouttelette partagera le même code barre unique à la cellule et sera lié à un seul UMI.

Création d'une librairie. Les librairies sont créées à partir du système Chromium (société 10xGenomics). On retire tout d'abord l'huile pour chaque cellule et son GEM. Les ADNc provenant d'une même cellule sont toujours regroupés ensemble. Tout d'abord, les séquences sont limitées, grâce à l'ajout de courtes séquences à leurs extrémités, pour prévenir les hybridations possibles. Les fragments sont ensuite amplifiés. Le séquençage est couplé à une molécule fluorescente. Le séquençage synthétise des fragments complémentaires (ou reads en anglais). Ces fragments sont de deux types, "Forward" ou "Reverse" qui respectivement représentent un brin et son brin complémentaire. Les fragments séquençés sont ensuite alignés par hybridation des deux types de brins. Finalement,




Fig. 1. Schema explicatif de la technique de séquençage d'ARNm sur cellules uniques (credit : 10xGenomics)




Fig. 2. Distribution du nombre d'UMI avec (a) Histogramme du nombre d'UMI par cellule avec le nombre de cellules en échelle log. Les deux lignes rouge représentent les seuils de filtrage du nombre d'UMI. et (b) Histogramme du nombre d'UMI par gène avec le nombre de cellules en échelle log.

les fragments créés seront regroupés en librairie, c'est à dire regroupé grâce à leur code barre unique (spécifique à une cellule). Nous obtiendrons donc une matrice d'expression représentant la quantité d'ARNm séquençées par gène (séquence d'ADN codante) et des cellules.

Description et filtrage des données.

Lors du séquençage on récupère environ 65% des cellules et environ 30% des ARNm (25). La matrice obtenue est ainsi de type creuses (ou sparse matrix en anglais). Cependant, toutes les observations (cellules) de notre matrice ne sont pas pertinentes, en effet, lorsque le nombre d'UMI par librairie est trop élevé, cela peut être dû à des doublets, c'est à dire la liaison de plusieurs cellules à une même bille. De la même façon, un nombre trop faible d'UMI par cellules peut correspondre à une cellule dont la membrane a été trouée, une cellule en sénescence (dont les seuls ARNm séquençés seraient les ARNm mitochondriaux) ou encore une bille peut ne pas avoir ciblé de cellules (26). Notre matrice d'expression comprends 9506 gènes (variables) et 5223 cellules (ou code barre)

Filtrage des données selon le nombre d'UMI. Comme dit précédemment, il est indispensable de supprimer les cellules qui possèdent trop peu, ou trop d'UMI. L'intervalle des cellules conservé est fixé arbitrairement entre 12 000 et 100 000 UMI par cellules (figure 2a)

1. Methode 1 : Utilisation du paquet scprep. Une première méthode de filtrage des données correspond à l'utilisation du paquet scprep.

2. Methode 2 : Methode alternative. Une methode alternative consiste à compter le nombre d'UMI par cellule (total des




Fig. 3. Histogramme représentant la proportion de gènes mitochondriaux par cellules : La ligne verticale rouge correspond au seuil de 30% de gènes mitochondriaux




Fig. 4. Histogramme représentant la distribution du nombre d'UMI par cellule après le filtrage

UMIs par colonne), puis de les retirer à l'aide de la fonction `drop` du paquet [pandas](#). / Les deux méthodes nous donnent des résultats similaires.

Filtrage des données selon les gènes mitochondriaux. Lors du séquençage des ARNm, des ARNm mitochondriaux sont aussi séquencés en faible proportion (fig.3). De plus, on sait qu'un taux de gène mitochondrial élevé est le signe d'une cellule en mort cellulaire. En effet, les ARNm mitochondriaux sont contenus dans les mitochondries, et, lorsque la membrane mitochondriale est percée, ces ARNm peuvent se déplacer vers le cytoplasme de la cellule, et ainsi être détectés par le séquençage. Ici, on fixe le seuil de décision à 30% des gènes mitochondriaux par cellule. On a 272 cellules avec un taux supérieur à 30% de gène mitochondrial pour toutes nos données avant tout filtrage. Après le filtrage des UMIs on retrouve au final 2 cellules avec plus de 30% de gène mitochondrial (avec 43.7% et 33.10% de gènes mitochondriaux).

Après ce filtrage, on retrouve une matrice d'expression de 1098 cellules et 9506 gènes. Les données sont représentées dans un histogramme représentant le nombre d'UMI par cellule (fig.4).

Nombre d'UMI médian et normalisation. Il y a 31193.0 UMI médian par cellules (noté M), c'est à dire que 50% des cellules ont plus que cette valeur, et 50% de cellules ont moins d'UMI que cette valeur. Ce nombre médian va servir pour la normalisation de nos données. Il est ensuite nécessaire de normaliser nos données pour la suite de nos calculs (26). En effet, il est nécessaire de normaliser nos moyennes et nos écarts types




Fig. 5. Distribution du nombre d'UMI par cellules après filtrage et normalisation




Fig. 6. Distribution des coefficients de variations des gènes par cellules

pour ensuite utiliser des algorithmes de regroupements. Ainsi x représente chaque donnée à normaliser.

$$X_{norm} = \log\left(\sum \frac{x}{M} * M + 1\right) \quad [1]$$

Nos données sont ainsi filtrées et normalisées (fig. 4).

Identification des cellules épithéliales.

Filtrage des données selon le coefficient de variation. Le coefficient de variation permet de visualiser la distribution relative des données. Il semble y avoir plusieurs façons de calculer le coefficient de variation.

Utilisation du paquet Scipy Une méthode de calcul consiste à utiliser le paquet [Scipy](#). Ce dernier utilise un écart type biaisé.

$$CV = \frac{s}{\bar{x}} \quad [2]$$

On remarque un maximum du coefficient de variation de 33.12. C'est la valeur pour laquelle la distribution est la plus éloignée de la moyenne (fig.6). On sélectionne les 1500 gènes les plus variables sur les 9506 gènes. On admet ici que les autres gènes ne varient que très peu entre les différentes cellules, et donc entre les différentes conditions.

ACP Méthode 1 : Utilisation du paquet sklearn

Pour visualiser les données nous réalisons une Analyse en Composante Principale (ACP). Cette méthode permet de visualiser les données indépendamment les unes des autres. En effet, certains gènes peuvent ici être liés les uns aux autres (par exemple un gène régule un autre gène). L'ACP résume de plus la structure de corrélation entre les données (diagonalisation




Fig. 7. Nombre de composantes optimales en fonction des valeurs propre




Fig. 8. Variance expliquée par les gènes

d'une matrice de variance et co-variance). Enfin, elle permet de réduire ce que l'on appelle le fléau de la dimension (*curse of dimensionality* en anglais), qui correspond à un biais dans l'analyse de donnée avec un trop grand nombre de variables (27). Ici nous avons une base de données de 1500 gènes (variables), or il est nécessaire de réduire le nombre de variable avant d'analyser les données. Ainsi, on procédant à une ACP, on peut choisir le nombre de variables avec les quels on va poursuivre notre analyse.

La première méthode consiste à utiliser le paquet [sklearn](#). Pour se faire nous commençons par réaliser une ACP. Nous utilisons une valeur corrigée de l'ACP pour la suite.

$$eigval = \frac{n - 1}{n * \text{acp.variance}_{expliquée}} \quad [3]$$

Une des façon pour déterminer le nombre de composantes (variables) à conserver consiste à utiliser la règle du coude (représenté par un *Scree plot* en anglais)(fig.7).

On peut aussi visualiser les dimensions (c'est à dire les variables) qui expliquent la variance expliquée cumulée (fig.8)

On visualise l'ACP avec cette méthode (fig.9). Cependant, cette méthode ne semble pas optimale pour les raisons expliquées plus haut (valeurs biaisées), aussi nous allons utiliser une autre méthode.

ACP Methode 2 : Utilisation du paquet Scanpy

On utilise donc notre matrice (au format DataFrame) normalisée, et filtrée par le nombre d'UMI et le pourcentage de gènes mitochondriaux. Nous avons donc une matrice de 1098 cellules (observations) et 9506 gènes (variables). On utilise le paquet [Scanpy](#) permettant l'analyse des données issus de séquençage d'ARNm sur cellules uniques La première étape est




Fig. 9. ACP en 2 dimensions : méthode 1



Fig. 10. ACP en 2 dimensions : méthode 2

de transformer nos données en objet *Anndata*. Pour se faire il est nécessaire de transposer nos données normalisées. On peut ensuite réaliser une ACP avec Scanpy et visualiser le pourcentage de variances cumulées en fonction des composantes. L'ACP sera ajusté avec les gènes les plus variables. On peut présenter l'ACP annoté avec le nom des cellules (Fig.S3). On peut aussi utiliser la technique du coude pour visualiser le nombre de composante optimal. Nous utiliserons donc nos données avec les 8 composantes de l'ACP pour la suite.

Différents types de regroupement cellulaire. Pour identifier les types cellulaires nous utiliserons une liste fournie de gènes qui sont essentiellement exprimés dans un type cellulaire particulier (Table 1).

1. Partitionnement en K-moyennes

Ce type d'algorithme permet de calculer le nombre de groupe optimal (ou cluster en anglais). Etant impossible de visualiser des données en 8 dimensions de façon claire, nous nous baserons sur la mesure silouhette pour évaluer la cohérence du nombre de groupe.

$$\text{ScoreSilouhette} = \frac{(b - a)}{\max(b, a)} \quad [4]$$

Avec respectivement a et b pour la distance moyenne au sein du groupe et b la distance moyenne avec un autre groupe. 2.

Table 1. Liste des gènes utilisés pour la catégorisation

Type cellulaire	Gènes
Muscle	blow, Grip, Him, htl, Pdp1, sls
Pre-muscle	sns, Strn-Mlck, TpnC73F, sis
Tendon	Alk, Hand, kon, vkg
SOP	ase, cpo, sca, sens
Hemocyte	eater, et, NimC4, srp
Epithéliale	arm, baz, grh, hth, shg, zip,eyg'

dessus sont essentiellement exprimés dans le type cellulaire indiqué

Regroupement hiérarchique Une autre façon consiste à utiliser le regroupement hiérarchique, toujours en vérifiant le nombre de groupe optimal par le score silhouette. Il y a 3 types de paramètres, 'ward', 'average' et 'complete' correspondant à la méthode de calcul des distances utilise, respectivement la distance minimale, la distance moyenne et la distance maximale.

3. Partitionnement spectral Cette dernière technique est utilisée pour des données non linéairement séparable, en utilisant des vecteurs propres et des matrices de similarités.

Utilisation de PAGA pour la discrimination des groupes. PAGA (pour Partition-based graph abstraction en anglais) est une technique spécifique de l'analyse du séquençage d'ARNm sur cellules uniques. Cette technique infère des groupes à partir d'une base de donnée, et permet leurs visualisation en préservant la topologie globale du graphique (28)(visualisable par le paquet Umap. Nous nous aidons d'un tutoriel pour réaliser le regroupement. PAGA utilise le paquet [louvain](#) qui permet d'identifier des "communautés" de gènes. Ce paquet nécessite l'installation du paquet Igraph. Il faut ainsi vérifier que ce dernier ne rentre pas en conflit avec la paquet R du même nom.

On visualise les réseaux inférés en spécifiant nos gènes cibles (tableau 1). Certains gènes ont été filtrés (s'ils n'étaient exprimés que dans des cellules qui ont été filtrés ou s'ils ne font pas partis des 1500 gènes les plus variables), aussi, tous les gènes ne sont pas présents pour la visualisation via Louvain. Après les avoir visualisés on remarque une échelle d'expression relative de gènes allant du jaune (maximum) à violet (minimum) au sein d'un groupe. Ainsi, notre décision se fera en fonction de la valeur d'expression au sein d'un groupe. La méthode est la suivante : Groupe par groupe, de 0 à 14, nous listons les gènes les plus exprimés (jaune) et quand il n'y a pas de gènes très exprimés, nous choisissons ceux avec le plus d'expression (jusqu'à vert clair). Ensuite, nous décidons si un groupe est représentatif d'un type cellulaire (par exemple le groupe 0 ne contient que des gènes essentiellement exprimés dans les cellules épithéliales), ou si un groupe est dit mixtes (par exemple groupe 11 constitué de cellules épithéliale et de SOP (precursseurs des organes sensoriels). Pour la validation des groupes nous utilisons les gènes de validations fournis (table 2). Il suffit ensuite de vérifier que les gènes qui sont exprimés dans les cellules épithéliales correspondent aux gènes épithéliaux, qu'on ne retrouve pas de gène d'exclusion des

Table 2. Liste des gènes de validation

Type cellulaire	Gènes
Exprimés dans quelques cellules épithéliale	dpy, nw
Non exprimé dans les cellules épithéliale	Act57B, Act87E, htl, grip, twi
Plus exprimés dans les cellules musculaire	blow, kon, Sox100B,twi

Gènes utilisés pour la validation des groupes

cellules épithéliales dans les groupes de cellules épithéliales, et que les groupes musculaires exprime plus les gènes exprimés dans les cellules musculaires. Enfin, pour vérifier ces résultats nous effectuerons un test de Student (test-t) via les gènes les plus exprimés au sein de chaque groupes. Le cellules peuvent ainsi être catégorisée par groupe, et sont récupérable avec la fonction `adata.obs['louvain_anno']`.

Resultats

Description des données et filtrage. Il y a en moyenne 14503.89 (± 41895.24) UMI par cellules. On remarques tout d'abords que les données sont très hétérogènes (fig.2 (a)). Il y a en moyenne 7969.05 (± 69061.29) UMI par gène. On remarque ici que la distribution est plus regroupée, avec quelques gènes très exprimés (fig.2 (b)). Peu de cellules possèdent plus de 10% de gènes mitochondriaux (fig.3). Les cellules une fois filtrée (fig.4) et normalisée (fig.5) semblent normalisée.

Identification des cellules epitheliales. Avec la première méthode de calcul des gènes les plus variables à l'aide du coefficient de variation, on remarque que la majorité des gènes varient très peu (avec un coefficient de variation inférieur à 5) (fig.6).

Ici on peut supposer que le nombre optimal de composant à conserver se situe entre 6 et 10. Par commodité nous utiliserons 8 composantes pour le reste du projet (cette valeur aillant était choisi à postériori de l'analyse totale des résultats) (fig.7). De plus, on remarque que 50% de la variances est expliquée par 75 dimensions. Il semble donc que choisir 8 dimensions soit un très mauvais choix. De plus quand on visualise l'ACP avec cette première méthode, on retrouve des résultats illisibles (fig.9). Enfin, on remarque que d'après la carte de chaleur (fig. S1) que les données ne semblent pas du tout cohérentes (aucune cellules proches, ou pas de gènes qui covarie ensembles) Aussi, on décide de passer à une seconde méthode. La seconde méthode consiste à utiliser les objets Anndata. On commence par regarder les gènes les plus variables (fig.S2). On remarque que le paquet peut réaliser une normalisation supplémentaire. En visualisant l'ACP (fig.10) on remarque qu'il semble y avoir 2 groupes quand on choisi 8 composantes et qu'on visualise la première et la deuxième composante principale. De plus, on voit que les 8 composantes (notée de 0 à 7) expliquent 57,5% de la variances (fig. 11). En visualisant les variances expliquées en fonction du nombre de dimension (fig.12) on remarque que le nombre de composante optimale semble être 5. Cependant, par commodité, on continuera l'analyse avec 8 composantes comme expliqués plus haut.

Différents types de regroupement cellulaire. On a utilisé 3 types différents d'algorithmes, les K-moyen, le regroupement hiérarchique et le regroupement spectral. On a différents




Fig. 11. Pourcentage de variance expliquée cumulée en fonction du nombre de dimension




Fig. 12. Variances expliquées en fonction du nombre de dimensions optimales

coefficient de silhouette qui indique la pureté d'un groupe. Cette technique consiste à calculer les distances entre les plus proches voisins des points au sein du groupe. Si le plus proche voisin d'un point fait partie du groupe, alors on aura une distance positive, et si c'est l'inverse, alors on aura une distance négative. Le score final correspond à la somme de toutes les distances. Pour l'algorithme du K-moyens, le meilleur score silhouette correspond à 4 groupes, pour un score de 0.434 environs. Concernant le regroupement hiérarchique, le score silhouette maximal est de 0.57 pour 3 groupes avec pour paramètre 'ward' expliqué plus haut. On retrouve un score silhouette de 0.52 toujours pour 3 groupes pour le paramètre 'average' et enfin pour le paramètre 'complete' on retrouve un nombre optimal de 7 groupes pour une score silhouette de 0.40.

Utilisation de PAGA pour le partitionnement de nos données.

On retrouve 15 groupes avec Louvain (fig.13). On visualise l'expression relative des gènes dans chaque groupe (fig.14). Ainsi, on nomme les 15 groupes en fonction des gènes exprimés qui les constituent. Tous les groupes ne sont pas reliés les uns aux autres de la même façon avec par exemple le groupe 3 qui n'est relié qu'à un seul autre groupe (le 7) ou encore le groupe 10 qui semble être relié au plus grand nombre de groupe.

On choisit le type de groupe comme expliqué dans la méthode et présentés dans la figure S4 (fig.S4). Les gènes de validations sont bien présents dans des groupes cohérents à leurs caractéristiques (fig.S5). On peut appliquer un test t sur




Fig. 13. Louvain identifie 15 groupes pour les données avec les 1500 gènes les plus variables

les 10 gènes les plus variables par exemples, pour confirmer que les groupes sont différents les uns des autres (fig. S6)

Enfin, on visualise nos données labélisées grâce à un umap. On passe ainsi de 15 groupes à 5 groupes, les cellules épithéliales, les cellules musculaires, les cellules musculaire + pré-musculaire, les hémocytes + tendons, les épithéliales + SOP.

Discussion. Après la filtration de nos données (fig.2, fig3, fig4, fig5) on obtient des données normales visuellement. Tout d'abord on remarque que les gènes sont peu variables dans la première méthode (méthode 1) (fig.6), ce qui peut être expliquée par le fait que nous utilisons une matrice creuse. Cependant, après l'analyse des résultats (50% de la variance expliquée par 75 dimensions)(fig.7 et fig.8) ou encore la visualisation de l'ACP (fig.9), on remarque que la méthode semble biaisée. Ainsi l'identification des gènes les plus variables est déterminante, et peut fausser les résultats dès le début. Il existe plusieurs façon d'identifier ces gènes, et le coefficient de variation sur une matrice creuse ne semble pas être la méthode optimale

En utilisant la seconde méthode (Scanpy) on remarque que les ACP sont différentes (fig. 10), cette fois on retrouve 2 groupes distincts pour les 2 premières composantes. Sur cette figure les axes sont notés en anglais par Scanpy, aussi PC signifie Principal component pour Composante Principale (CP) De plus cette fois, sur les 9506 variables on a 57,5% de la variance qui est expliquée par les 8 composantes (fig.11). Cette méthode semble plus fiable. Ici, d'après la méthode coude, il semble que le nombre optimal de composante soit de 4, mais par sécurité nous garderons les 8 composantes.

L'utilisation de Scanpy couplé à Louvain permet d'identifier 14 groupes (fig.13). Cependant, il semble impossible de fixer le nombre de groupe à identifier en amont, ce qui aurait pu être intéressant. L'identification des groupes se fait suivant la méthode expliquée en Fig. S4 (Fig.S4) grâce aux données obtenues en figure 4 (fig.4). Ici, certains gènes du tableau 1 ont été filtrés. D'après la figure 14 (fig. 14) et la figure S7 (Fig.7) les groupes de muscles sont proches les uns des autres. Le groupe mixte de muscle + pré-muscle est proche d'un groupe de muscle. Les groupes des cellules épithéliales sont agglomérés les uns avec les autres. Les cellules épithéliales + les SOP sont reliés les uns aux autres et avec les cellules épithéliales. Enfin le groupe d'hémocytes + tendon est relié avec des groupes musculaires et des groupes de cellules épithéliales tout en étant isolé du reste.

Nous retrouvons 6 groupes, cependant cela ne correspond à aucun nombre optimal de groupe trouvé par les autres méth-




Fig. 14. Expression relative des gènes au sein des groupes inférés (a) Réseau inféré par louvain avec 15 groupes numérotés et (b) Expression relative des gènes présents essentiellements dans les cellules musculaires (c) dans les cellules pré-musculaire, (d) dans les tendons, (e) dans les SOP c'est à dire les précurseurs des organes sensoriels,(f) dans les hémocytes et (g) dans les cellules épithéliale)




Fig. 15. Visualisation des 6 groupes labélisés à partir de 14 groupes identifiés

odes de partitionnement (K-moyens, hiérarchique et spectral). Les scores de silhouette de ces différentes techniques n'étaient pas très haut, ce qui peut expliquer ces résultats. On obtient ainsi 6 groupes de cellules qui sont visible grâce au paquet UMAP (fig. 15). Ainsi, nous avons bien réussi à identifier des groupes de cellules épithéliales pures, qui pourront permettre l'étude de la morphogénèse chez la drosophile.

Cependant il y a plusieurs limites à notre travail. D'une part, nos données sont dites creuses, nous n'avons en effet que 30% de l'expression des ARNm qui ont été capturée par la technique du séquençage d'ARNm sur cellules uniques (pour 60% cellules capturées). Une autre limite de notre travail concerne les UMIs, en effet, il semble que la technique du séquençage sur cellules uniques comprennent souvent des erreurs (29). De plus, comme dit précédemment nous avons dû réduire la dimensionnalité de nos variables, cependant 8 composantes ne semblent pas être le nombre optimal de variables, et n'expliquent que peu la variance expliquée. On peut aussi rappeler le fléau de la dimensionnalité (27). Enfin, nos groupes ont été inférés, il faudrait une technique d'identification biologique pour valider ces groupes, en effet, les gènes de validations donnés ne permettent pas forcément de déterminer les faux négatifs (dans le cas des cellules épithéliales).

Ainsi, nous avons inféré des groupes cellulaires, cependant, il est crucial d'avoir une méthode plus robuste que celle présentée dans ce rapport, pour permettre de suivre des cellules au cours du temps. Les groupes déterminés par les algorithmes classiques (K-moyen, hiérarchique et spectral) ne semblent pas suffisamment robuste, et le paquet PAGA, bien qu'intéressant, ne semble pas très flexible.

Données supplémentaires. Des données supplémentaires sont disponibles dans le fichier (donnée supplémentaire)

References.

1. Morgan TH (1910) SEX LIMITED INHERITANCE IN DROSOPHILA. *Science (New York, N.Y.)* 32(812):120–122.
2. Kaufman TC (2017) A Short History and Description of Drosophila melanogaster Classical Genetics: Chromosome Aberrations, Forward Genetic Screens, and the Nature of Mutations. *Genetics* 206(2):665–689.
3. Adams MD, et al. (2000) The genome sequence of Drosophila melanogaster. *Science (New York, N.Y.)* 287(5461):2185–2195.
4. Gratz SJ, Rubinstein CD, Harrison MM, Wildonger J, O'Connor-Giles KM (2015) CRISPR-Cas9 genome editing in Drosophila. *Current protocols in molecular biology / edited by Frederick M. Ausubel ... [et al.]* 111:31.2.1–31.2.20.
5. Emery P, Stanewsky R, Hall JC, Rosbash M (2000) A unique circadian-rhythm photoreceptor. *Nature* 404(6777):456–457.
6. Emery P, So WV, Kaneko M, Hall JC, Rosbash M (1998) CRY, a Drosophila Clock and Light-Regulated Cryptochrome, Is a Major Contributor to Circadian Rhythm Resetting and Photosensitivity. *Cell* 95(5):669–679.
7. Huang RC (2018) The discoveries of molecular mechanisms for the circadian rhythm: The 2017 Nobel Prize in Physiology or Medicine. *Biomedical Journal* 41(1):5–8.
8. Imler JL, Hoffmann JA (2001) Toll receptors in innate immunity. *Trends in Cell Biology* 11(7):304–311.
9. Muskavitch MAT (1994) Delta-Notch Signaling and Drosophila Cell Fate Choice. *Developmental Biology* 166(2):415–430.
10. Lewis EB (2004) A Gene Complex Controlling Segmentation in Drosophila in *Genes, Development and Cancer: The Life and Work of Edward B. Lewis*, ed. Lipshitz HD. (Springer US, Boston, MA), pp. 205–217.
11. Hogan BLM (1999) Morphogenesis. *Cell* 96(2):225–233.
12. Suzanne M, Steller H (2013) Shaping organisms with apoptosis. *Cell Death & Differentiation* 20(5):669–675.
13. Olguin P, Glavic A, Mlodzik M (2011) Intertissue Mechanical Stress Affects Frizzled-Mediated Planar Cell Polarity in the Drosophila Notum Epidermis. *Current Biology* 21(3):236–242.
14. Hara Y (2017) Contraction and elongation: Mechanics underlying cell boundary deformations in epithelial tissue. *Development, Growth & Differentiation* 59(5):340–350.
15. Bras SL, Borgne RL (2014) Epithelial cell division – multiplying without losing touch. *Journal of Cell Science* 127(24):5127–5137.
16. Guillot C, Lecuit T (2013) Mechanics of Epithelial Tissue Homeostasis and Morphogenesis. *Science* 340(6137):1185–1189.
17. Gracia M, et al. (2019) Mechanical impact of epithelial-mesenchymal transition on epithelial morphogenesis in Drosophila. *Nature Communications* 10(1):2951.
18. Guirao B, et al. (year?) Unified quantitative characterization of epithelial tissue development. *eLife* 4.
19. Lecuit T, Yap AS (2015) E-cadherin junctions as active mechanical integrators in tissue dynamics. *Nature Cell Biology* 17(5):533–539.
20. Zarnescu DC, Thomas GH (1999) Apical spectrin is essential for epithelial morphogenesis but not apical-basal polarity in Drosophila. *The Journal of Cell Biology* 146(5):1075–1086.
21. Bilder D (2004) Epithelial polarity and proliferation control: links from the Drosophila neoplastic tumor suppressors. *Genes & Development* 18(16):1909–1925.
22. Hannezo E, Prost J, Joanny JF (2014) Theory of epithelial sheet morphology in three dimensions. *Proceedings of the National Academy of Sciences of the United States of America* 111(1):27–32.
23. Wu AR, et al. (2014) Quantitative assessment of single-cell RNA-sequencing methods. *Nature Methods* 11(1):41–46.
24. Fan J, Han F, Liu H (2014) Challenges of Big Data analysis. *National Science Review* 1(2):293–314.
25. (year?) 10x Genomics: Single Cell Gene Expression Solution.
26. Lueken MD, Theis FJ (2019) Current best practices in single-cell RNA-seq analysis: a tutorial. *Molecular Systems Biology* 15(6):e8746.
27. Altman N, Krzywinski M (2018) The curse(s) of dimensionality. *Nature Methods* 15(6):399–400.
28. Wolf FA, et al. (2019) PAGA: graph abstraction reconciles clustering with trajectory inference through a topology preserving map of single cells. *Genome Biology* 20(1):59.
29. Smith T, Heger A, Sudbery I (2017) UMI-tools: modeling sequencing errors in Unique Molecular Identifiers to improve quantification accuracy. *Genome Research* 27(3):491–499.